SISTEMI AD AGENTI · A.A. 2025/26

Chatbot clinico per la stima del rischio

Un agente conversazionale che raccoglie dati clinici attraverso un dialogo guidato e li trasforma in una stima di rischio, usando embedding semantici biomedici e un classificatore addestrato su dati reali.

❤️ Heart Disease | 🏥 Diabetes Readmission | BioBERT · 768-d | Streamlit · Telegram

Corso di **Sistemi ad Agenti** Docente: **Prof.ssa Berardina De Carolis** **Università degli Studi di Bari "Aldo Moro"**

PERCORSO

Di cosa parliamo

01	**Cos'è un chatbot, e perché è un agente**	slide 3–5
02	**Dal dialogo alla predizione**	slide 6–9
03	**Classificazione e apprendimento**	slide 10–13
04	**I due dataset e come scegliere**	slide 14–16
05	**Come si esegue il progetto**	slide 17–18
06	**Librerie, limiti e sviluppi**	slide 19–20

Cos'è un chatbot

Un sistema software che interagisce con l'utente in **linguaggio naturale**, attraverso turni di dialogo, per fornire informazioni o portare a termine un compito.

ASSE 1 · SCOPO

Task-oriented vs open-domain

Obiettivo preciso in un dominio chiuso (prenotare, diagnosticare) oppure conversazione libera senza compito.

ASSE 2 · RISPOSTA

Regole · retrieval · generativo

Risposte scritte a priori, recuperate da una base di conoscenza, o generate da un modello linguistico.

ASSE 3 · DIALOGO

Slot-filling · frame · piani

Riempimento sequenziale di campi, gestione a frame con più intenti, o pianificazione dinamica dei turni.

Dove si colloca il nostro sistema

Task-oriented (un solo compito: stimare un rischio clinico) · dialogo **a regole con slot-filling deterministico** · ma la conclusione non è una regola: è la previsione di un **modello statistico appreso dai dati**. È un ibrido — regole per condurre la conversazione, machine learning per decidere.

Il chatbot come agente: descrizione PEAS

P · PERFORMANCE

Qualità della stima (ROC-AUC, macro-F1), questionario portato a termine, robustezza agli input non validi, trasparenza dell'esito (probabilità + soglia + avvertenza).

E · ENVIRONMENT

Conversazione testuale con un utente umano via Streamlit o Telegram. **Parzialmente osservabile** (vede solo ciò che l'utente dichiara), **episodico** (una sessione = una valutazione), deterministico, statico, discreto.

A · ACTUATORS

Messaggi di testo: la domanda successiva, un messaggio d'errore mirato, oppure l'esito finale con probabilità stimata e disclaimer.

S · SENSORS

I messaggi di testo dell'utente, interpretati da **parser specifici per tipo di slot** (scelta, intero in intervallo, decimale, codice etichettato).

Proprietà dell'agente

Autonomia: decide da sé quale domanda porre e quando concludere · **Reattività**: risponde a ogni turno dell'utente · **Orientamento all'obiettivo**: completare gli slot e produrre la stima · **Persistenza dello stato**: ricorda le risposte già date nella sessione.

Architettura dell'agente

Sensore — messaggio dell'utente

`handle_message(session, text)` riceve il turno

↓

Interpretazione — parser dello slot corrente

Validazione del valore; se fallisce, l'errore non fa avanzare lo stato

↓

Stato interno — `ConversationSession`

Risposte raccolte (`answers`) + indice della domanda (`step`)

↓

Decisione appresa — solo a slot completi

`record_to_text → BioBERT → LogisticRegression → soglia τ`

↓

Attuatore — risposta testuale

Domanda successiva · messaggio d'errore · esito finale

Che tipo di agente è

Un **agente basato su modello, con stato interno**: non è puramente reattivo, perché la risposta dipende da quanto già raccolto nella sessione, non solo dall'ultimo messaggio.

Dove sta l'apprendimento

La componente decisionale è **appresa offline**, prima che la conversazione inizi. Durante il dialogo l'agente **non apprende**: applica un modello già addestrato e congelato.

Un solo cervello, due canali

Streamlit e Telegram chiamano lo stesso `chatbot_core` : la logica dell'agente è unica, cambia soltanto il mezzo di comunicazione.

Il dialogo: slot-filling guidato

Ogni dataset ha una **lista ordinata di domande**, una per feature. Ciascuna definisce quattro cose:

`field` — il campo da riempire
`prompt` — la domanda da porre
`parser` — come interpretare e validare
`error` — cosa dire se il valore non è valido

La regola di avanzamento

Se il parser restituisce un valore valido → salva e passa alla domanda dopo. Se restituisce `None` → ripete l'errore **senza avanzare**. L'agente non accetta mai un valore che non sa interpretare.

13
DOMANDE · HEART

19
DOMANDE · DIABETES

CONVERSAZIONE REALE

Ciao! Sono un assistente che stima il rischio clinico in base ad alcuni dati di base. ⚠️ Non sono uno strumento diagnostico.

Sei uomo o donna? (rispondi 'uomo' o 'donna')

uomo

Quanti anni hai?

centoventi

Inserisci un'età valida (un numero tra 1 e 120).

63

Che tipo di dolore al petto avverti?
1) angina tipica · 2) angina atipica · 3) dolore non anginoso · 4) asintomatico

1

Qual è la tua pressione arteriosa a riposo (mmHg)?

Come si arriva alla previsione

01 **Risposte raccolte** — il dizionario `answers` contiene un valore per ogni feature

02 **Record → testo** — `record_to_text()` compone una frase clinica in linguaggio naturale

03 **Testo → vettore** — BioBERT produce un embedding di 768 dimensioni

04 **Vettore → probabilità** — `predict_proba()` restituisce P(classe positiva)

05 **Probabilità → etichetta** — confronto con la soglia τ appresa

06 **Risposta** — esito, probabilità, soglia e avvertenza esplicita

OUTPUT REALE DELL'AGENTE

In base ai dati forniti, il paziente risulta **a RISCHIO di malattia cardiaca**.

Probabilità stimata: **78.4%** (soglia di decisione: 39.0%).

⚠️ Questo è solo un supporto informativo basato su un modello statistico, non una diagnosi medica. Consulta sempre un professionista sanitario.

Scrivi 'nuovo' per fare un'altra valutazione.

Perché trasformare i dati in una frase

Il modello di embedding è stato addestrato su **testo biomedico**. Dandogli una frase invece di una riga di numeri, sfruttiamo la conoscenza linguistica che ha già.

Cosa guadagniamo

Le etichette diventano parole che il modello ha già visto in letteratura medica — "angina tipica", "difetto reversibile" — invece di codici numerici (1, 2, 3) che da soli non significano nulla.

Un solo punto di verità

`record_to_text()` è usata sia per addestrare sia per rispondere in chat. Addestramento e inferenza non possono divergere.

LA FRASE REALMENTE GENERATA E DATA IN PASTO AL MODELLO

```
Male patient, 63 years old,
chest pain type: angina tipica,
resting blood pressure: 145 mm Hg,
serum cholesterol: 233 mg/dl,
fasting blood sugar > 120 mg/dl: yes,
resting electrocardiographic results: normale,
maximum heart rate achieved: 150,
exercise-induced angina: no,
ST depression induced by exercise: 2.3,
slope of the peak exercise ST segment: discendente,
number of major vessels colored by fluoroscopy: 0,
thalassemia: difetto fisso
```

Gli embedding semantici

Un **embedding** è un vettore numerico che rappresenta il significato di un testo: frasi con contenuto simile producono vettori vicini nello spazio.

768
DIMENSIONI

1
VETTORE PER PAZIENTE

MODELLO USATO

`pritamdeka/BioBERT-mnli-snli-scinli-scitail-mednli-stsb`

Un **sentence-transformer** costruito su **BioBERT**: BERT pre-addestrato su letteratura biomedica (PubMed) e poi specializzato nel produrre vettori di frase confrontabili tra loro.

Perché questo e non un modello generalista

In un confronto preliminare tra encoder generalisti e biomedici su entrambi i dataset, è risultato il migliore per **ROC-AUC**. Da qui la scelta di fissarlo come unico encoder del sistema (`EMBEDDING_MODEL` in `function.py`).

La classificazione

Regressione logistica

Combina linearmente i 768 valori dell'embedding e passa il risultato in una **funzione sigmoide**, che lo comprime in una probabilità tra 0 e 1. In codice: `LogisticRegression(max_iter=2000)`.

Perché un modello lineare e non una rete profonda

L'embedding ha già fatto il lavoro semantico pesante. Uno strato lineare su rappresentazioni congelate misura **quanto segnale è già presente** nel vettore, con molti meno parametri da stimare — decisivo su Heart Disease, dove i record sono poche centinaia.

La soglia di decisione τ

Non si usa 0.5. La soglia viene **appresa**: è quella che massimizza l'F1 sulla curva precision-recall, calcolata su ogni fold e poi mediata.

0.390
T · HEART DISEASE

0.376
T · DIABETES 130

Cosa significa una soglia bassa

Il sistema segnala "a rischio" anche quando la probabilità stimata è sotto il 50%: è **deliberatamente prudente**, perché in ambito clinico un falso negativo pesa più di un falso allarme.

Come il sistema impara, prima della conversazione

01 **preprocessing.py** — carica i dati grezzi, imputa i valori mancanti, divide 80/20 e bilancia le classi con SMOTENC → restituisce `X, y`

02 **embedding.py** — converte ogni record in frase e genera i vettori BioBERT → salva `.npy` in `datas/<dataset>/embeddings/`

03 **classification.py** — validazione incrociata a 5 fold, calcolo delle metriche e della soglia → `model_performance.csv`

04 **chatbot_core.py** — riaddestra il classificatore su *tutti* gli embedding e carica la soglia salvata → l'agente è pronto

Ogni avvio riparte da zero

`clean_output_dirs()` svuota le cartelle del dataset prima di ricostruire: nessun risultato di una esecuzione precedente può sopravvivere e mescolarsi con quella corrente.

Separazione netta dei due momenti

Le fasi 1–3 sono **apprendimento** e avvengono una volta sola, all'avvio. La fase 4 prepara l'**inferenza**, che poi si ripete a ogni conversazione senza ulteriore addestramento.

Preparazione dei dati e bilanciamento

PASSO 1

Imputazione

I valori mancanti vengono riempiti con la **mediana** (feature numeriche) o la **moda** (categoriali). Necessario perché SMOTENC e la generazione del testo non tollerano buchi.

PASSO 2

Split stratificato 80/20

La divisione conserva la proporzione delle classi, così la parte di addestramento non risulta sbilanciata per caso.

PASSO 3

SMOTENC

Genera record sintetici della classe minoritaria fino a pareggiare le due classi.

Perché SMOTENC e non SMOTE

SMOTE classico lavora in uno spazio numerico codificato: i record che genera non sono più traducibili in una frase sensata. **SMOTENC** gestisce insieme colonne numeriche e categoriali — interpola i numeri, assegna alle categorie il valore più frequente tra i vicini — quindi ogni record sintetico resta un **record clinico valido** e convertibile in testo esattamente come uno reale.

Risultato del bilanciamento

Heart Disease	407 / 407	814
Diabetes 130	14.214 / 14.214	28.428

Validazione e metriche

Validazione incrociata stratificata

`StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`: i dati vengono divisi in 5 parti che conservano la proporzione delle classi. A turno, 4 servono per addestrare e 1 per valutare.

Le tre metriche

Accuracy — quota di previsioni corrette. Leggibile, ma sensibile allo sbilanciamento.
Macro-F1 — media armonica di precisione e recall calcolata su entrambe le classi con lo stesso peso.
ROC-AUC — capacità di *ordinare* i pazienti per rischio, indipendente dalla soglia scelta.

Cosa succede in ogni fold

Addestra → stima le probabilità sulla parte tenuta fuori → calcola la curva precision-recall → sceglie la soglia che massimizza F1 → misura le metriche. I valori riportati sono la **media dei 5 fold**.

Perché la ROC-AUC è la metrica di riferimento

È l'unica che non dipende da τ: misura la qualità del modello separatamente dalla politica di decisione. Per questo è stata usata per scegliere l'encoder.

❤️ UCI Heart Disease

Compito: diagnosi. Stabilire se è presente una malattia coronarica, sulla base dei dati di una singola visita cardiologica.

Origine — quattro centri clinici

Cleveland Clinic Foundation	303
Hungarian Institute of Cardiology	294
University Hospital, Zurigo/Basilea	123
V.A. Medical Center, Long Beach	200
Totale concatenato	**920**

Pulizia specifica

In alcuni centri colesterolo e pressione mancanti sono registrati come `0`: valori fisiologicamente impossibili, quindi trattati come dati mancanti e imputati.

13 feature cliniche

età · sesso · tipo di dolore toracico · pressione a riposo · colesterolo · glicemia a digiuno · ECG a riposo · frequenza cardiaca massima · angina da sforzo · depressione del tratto ST · pendenza ST · vasi colorati da fluoroscopia · talassemia

Variabile target

`num > 0` → presenza di malattia. Il valore originale indica anche la gravità (1–4), ma viene **binarizzato**: presente / assente.

920
RECORD GREZZI

814
DOPO BILANCIAMENTO

🏥 UCI Diabetes 130-US Hospitals

Compito: prognosi. Prevedere se un paziente diabetico verrà **riammesso in ospedale entro 30 giorni** dalla dimissione.

Origine e scala

101.766 ricoveri di pazienti diabetici in **130 ospedali statunitensi**, raccolti tra il **1999 e il 2008**. Il progetto ne usa un **campione stratificato di 20.000** record, per contenere i tempi di calcolo mantenendo la proporzione delle classi.

Selezione delle colonne: 19 su circa 50

Escluse quelle quasi costanti (flag di dosaggio di farmaci rari) e quelle con troppi valori mancanti o prive di significato clinico (peso, codice assicurativo, identificativi del paziente).

19 feature

etnia · genere · fascia d'età · tipo di ammissione · modalità di dimissione · fonte di ammissione · giorni di degenza · numero di esami di laboratorio · procedure · farmaci somministrati · visite ambulatoriali, accessi al pronto soccorso e ricoveri nell'anno precedente · numero di diagnosi · glicemia massima · test A1C · terapia insulinica · cambio di terapia · farmaco antidiabetico prescritto

Variabile target

`readmitted == "<30"` → riammissione precoce. Le riammissioni oltre i 30 giorni e le non riammissioni contano entrambe come classe negativa.

20k
CAMPIONE USATO

28.428
DOPO BILANCIAMENTO

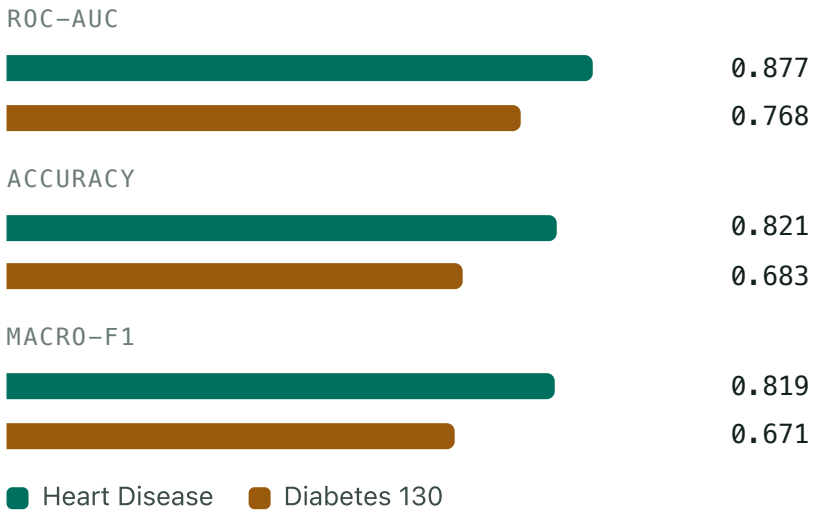
Confronto e criteri di scelta

CRITERIO	HEART DISEASE	DIABETES 130
Compito	**Diagnosi**	**Prognosi a 30 giorni**
Record grezzi	920	101.766
Usati per addestrare	814	28.428
Feature	13	19
Domande in chat	13	19
Natura dei dati	Cliniche / strumentali	Prevalentemente amministrative
Tempo di avvio	Minuti	Molto più lungo

Come scegliere

Cosa vuoi mostrare — diagnosi o previsione di riammissione · **Chi è l'utente** — Heart Disease chiede esami specialistici (ECG da sforzo, fluoroscopia), Diabetes 130 chiede dati che conosce il personale ospedaliero · **Quanto tempo hai** — 814 contro 28.428 embedding da generare.

RISULTATI · MEDIA SU 5 FOLD



Per la demo d'esame

Heart Disease: si avvia in pochi minuti, le domande sono riconoscibilmente cliniche e le metriche sono nettamente migliori.

05 · ESECUZIONE

Come si esegue il progetto

Prerequisiti

Python **3.11+** · connessione a internet al primo avvio (il modello BioBERT viene scaricato automaticamente) · un token **Telegram** solo se si usa quel front-end.

OPZIONE A · SCRIPT AUTOMATICO

```
# crea l'ambiente, installa, chiede cosa lanciare
./run_chatbot.sh

# oppure direttamente con i parametri
./run_chatbot.sh --dataset heart_disease \
                 --chatbot streamlit
```

OPZIONE B · MANUALE

```
python3 -m venv env
source env/bin/activate
pip install -r requirements.txt

python main.py --dataset heart_disease \
               --chatbot streamlit

python main.py --dataset diabetes130 \
               --chatbot telegram
```

Cosa succede a ogni avvio

`main.py` **ricostruisce il classificatore da zero** — pulizia, preprocessing, embedding, addestramento — e solo quando è pronto apre il chatbot. Con `diabetes130` l'attesa è sensibilmente più lunga: gli embedding da calcolare sono 28.428.

Token Telegram

File `.env` nella cartella del progetto:
`TELEGRAM_BOT_TOKEN=...` ottenuto da @BotFather.

05 · ESECUZIONE

I due front-end

APP_STREAMLIT.PY

Interfaccia web locale

Usa `st.chat_message` e `st.chat_input` per la chat; lo stato della conversazione vive in `st.session_state`, che sopravvive ai ri-render della pagina.

Se il dataset non è preimpostato da riga di comando, lo si sceglie direttamente nell'interfaccia prima di iniziare.

BOT_TELEGRAM.PY

Bot Telegram asincrono

Costruito con `Application` e due handler: `/start` e i messaggi di testo. Funziona in **polling**.

Mantiene un dizionario `sessions` indicizzato per `chat_id`: **più utenti possono conversare contemporaneamente**, ognuno con il proprio stato.

Un'unica logica, due canali

Entrambi i front-end si limitano a ricevere il testo e passarlo a `chatbot_core.handle_message()`, poi mostrano la risposta. Nessuna delle due interfacce contiene logica di dialogo o di predizione: cambiare canale non cambia il comportamento dell'agente. È la stessa separazione che, nella teoria degli agenti, distingue l'**agente** dai suoi **sensori e attuatori**.

Le librerie e il loro ruolo

LIBRERIA	VERSIONE	RUOLO NEL PROGETTO
sentence-transformers	`5.5.1`	Carica BioBERT e trasforma la frase clinica in un vettore di 768 numeri (`model.encode`). È il ponte tra testo e matematica.
transformers + **torch**	`5.7.0 / 2.11.0`	Motore sottostante del modello neurale: tokenizzazione del testo ed esecuzione della rete.
scikit-learn	`1.8.0`	Regressione logistica, validazione incrociata stratificata, metriche e curva precision-recall per la soglia τ.
imbalanced-learn	`0.14.2`	SMOTENC: bilancia le classi generando record sintetici che restano clinicamente interpretabili.
pandas	`3.0.2`	Lettura dei file `.data` e `.csv` , selezione delle colonne, imputazione dei mancanti.
numpy	`2.4.4`	Gestione e salvataggio degli array di embedding in formato `.npy` .
streamlit	`1.59.1`	Interfaccia chat web e persistenza dello stato della sessione.
python-telegram-bot	`22.8`	Bot Telegram asincrono: gestione degli handler e del polling dei messaggi.
python-dotenv	`1.2.2`	Carica il token Telegram da `.env` , tenendolo fuori dal codice sorgente.

Limiti dichiarati e sviluppi futuri

Non è uno strumento diagnostico

Il codice lo dichiara due volte: nel messaggio di benvenuto e dopo ogni previsione. È un supporto informativo basato su un modello statistico.

Asimmetria tra addestramento e uso

Nel training molti valori erano imputati; in chat l'utente fornisce sempre un valore reale. Le due situazioni non sono identiche.

Soglia e classificatore non perfettamente allineati

τ è la media delle soglie dei 5 fold, ma il classificatore finale viene riaddestrato su tutti i dati: non è esattamente lo stesso modello su cui τ è stata calibrata.

Dati storici e non italiani

Heart Disease risale al 1988, Diabetes 130 copre il 1999–2008, entrambi su popolazioni statunitensi ed europee.

Sviluppi possibili

Permettere "non lo so" — oggi ogni domanda richiede una risposta, anche quando l'utente non può conoscerla (fluoroscopia, ECG da sforzo).

Calibrare le probabilità — verificare che un "70%" corrisponda davvero a 7 casi su 10, non solo che l'ordinamento sia corretto.

Spiegare la previsione — indicare quali risposte hanno pesato di più sull'esito.

Validare lo scenario conversazionale — le metriche misurano il modello sui dati, non l'affidabilità del sistema usato da una persona reale.

In sintesi

Un agente conversazionale **task-oriented** che unisce un dialogo deterministico e verificabile a una decisione appresa dai dati, con le sue prestazioni **misurate** e i suoi limiti **dichiarati**.